

Байесовские методы подбора гиперпараметров

Фетисов Григорий

4 июня 2026 г.

План Работы

- 1 Постановка задачи
- 2 Используемые данные и модели
- 3 Используемые методы
- 4 Результаты

Байесовские
методы

Фетисов
Григорий

Постановка
задачи

Используемые
данные и
модели

Используемые
методы

Результаты

Постановка задачи

Байесовские
методы

Фетисов
Григорий

Постановка
задачи

Используемые
данные и
модели

Используемые
методы

Результаты

Постановка задачи

Цель: Автоматический подбор гиперпараметров моделей машинного обучения с помощью байесовской оптимизации.

Проблема:

- Ручной подбор гиперпараметров – трудоёмкий и неоптимальный процесс.
- Полный перебор (Grid Search) требует огромных вычислительных ресурсов.
- Случайный поиск не учитывает результаты предыдущих итераций.

Зачем нужно исследование:

- Найти лучшие гиперпараметры за меньшее число итераций.
- Сравнить эффективность разных методов байесовской оптимизации (GP, TRE).
- Проверить, на каких типах данных и моделях байесовские методы дают наибольший выигрыш.

Используемые данные и модели

Байесовские
методы

Фетисов
Григорий

Постановка
задачи

Используемые
данные и
модели

Используемые
методы

Результаты

Используемые модели

Тип	Классификация	Регрессия	Параметров
Линейные	LogisticRegression	Ridge, Lasso, ElasticNet	2–5
Деревья	RandomForestClassifier	RandomForestRegressor	5
Бустинг	CatBoostClassifier	CatBoostRegressor	6–8

Почему эти модели:

- **Разнообразие** Рассматриваем различные семейства моделей.
- **Быстрый процесс обучения** Позволяет делать эксперименты.
- **Универсальность** Несложно сделать единый пайплайн .

Метрики: ROC-AUC (классификация), MSE (регрессия).

Априорное распределение и зашумлённые наблюдения

Априорное распределение: Ещё не видя данных, для любого конечного множества $\mathbf{X}$ имеем:

$$p(\mathbf{f} \mid \mathbf{X}) = \mathcal{N}(\mathbf{f} \mid \mathbf{m}, \mathbf{K}_{XX})$$

где $\mathbf{m} = (m(\mathbf{x}_1), \dots, m(\mathbf{x}_n))^T$, $(\mathbf{K}_{XX})_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$.

Наблюдения с шумом: В задаче подбора гиперпараметров мы видим зашумлённые значения целевой функции:

$$y_i = f(\mathbf{x}_i) + \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(0, \sigma_n^2)$$

Тогда ковариационная матрица наблюдаемых данных:

$$\text{Cov}(y_i, y_j) = k(\mathbf{x}_i, \mathbf{x}_j) + \sigma_n^2 \delta_{ij} \iff \mathbf{K}_y = \mathbf{K}_{XX} + \sigma_n^2 \mathbf{I}$$

σ_n^2 — дисперсия шума наблюдений (настраиваемый гиперпараметр ГП).

Совместное распределение и апостериорный вывод

Задача: даны обучающие точки $(\mathbf{X}, \mathbf{y})$, нужно предсказать $\mathbf{f}_*$ в новых точках $\mathbf{X}_*$.

Совместное априорное распределение:

$$\begin{pmatrix} \mathbf{y} \\ \mathbf{f}_* \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \mathbf{m} \\ \mathbf{m}_* \end{pmatrix}, \begin{pmatrix} \mathbf{K}_{XX} + \sigma_n^2 \mathbf{I} & \mathbf{K}_{X*} \\ \mathbf{K}_{*X} & \mathbf{K}_{**} \end{pmatrix} \right)$$

Апостериорное распределение (обусловливание многомерного нормального):

$$\mathbf{f}_* | \mathbf{X}, \mathbf{y}, \mathbf{X}_* \sim \mathcal{N}(\boldsymbol{\mu}_*, \boldsymbol{\Sigma}_*)$$

$$\boldsymbol{\mu}_* = \mathbf{m}_* + \mathbf{K}_{*X}(\mathbf{K}_{XX} + \sigma_n^2 \mathbf{I})^{-1}(\mathbf{y} - \mathbf{m})$$

$$\boldsymbol{\Sigma}_* = \mathbf{K}_{**} - \mathbf{K}_{*X}(\mathbf{K}_{XX} + \sigma_n^2 \mathbf{I})^{-1}\mathbf{K}_{X*}$$

Вычислительная сложность: $O(n^3)$ из-за обращения матрицы $n \times n$.

Результаты

Байесовские
методы

Фетисов
Григорий

Постановка
задачи

Используемые
данные и
модели

Используемые
методы

Результаты

Результаты классификации (ROC-AUC)

Модель	Dataset	GP	TPE	Random	GP vs Rand	TPE vs Rand
CatBoost	Adult	0.9290	0.9292	0.9286	+0.05%	+0.07%
LogisticRegression	Adult	0.9057	0.9063	0.9061	-0.05%	+0.02%
RandomForest	Adult	0.9184	0.9185	0.9184	0.00%	+0.01%
CatBoost	Bank	0.8070	0.8071	0.8065	+0.06%	+0.07%
LogisticRegression	Bank	0.7713	0.7712	0.7712	+0.02%	0.00%
RandomForest	Bank	0.7963	0.7966	0.7965	-0.02%	+0.02%
CatBoost	Spam	0.9887	0.9883	0.9880	+0.07%	+0.03%
LogisticRegression	Spam	0.9723	0.9724	0.9723	0.00%	0.00%
RandomForest	Spam	0.9852	0.9842	0.9838	+0.15%	+0.04%

Таблица: Сравнение методов оптимизации на задачах классификации.

Жирным отмечен положительный прирост над случайным поиском, *курсивом* — отрицательный.

Краткий вывод

- Все три метода дают очень близкие результаты; прирост минимален (до +0.15%).

Результаты регрессии (neg MSE)

Модель	Dataset	GP	TPE	Random	GP vs Rand	TPE vs Rand
<i>California Housing (MSE $\times 10^9$)</i>						
CatBoost	California	-1.99	-2.01	-2.06	+3.06%	+2.11%
ElasticNet	California	-4.77	-4.77	-4.77	+0.01%	+0.01%
Lasso	California	-4.77	-4.77	-4.77	0.00%	0.00%
RandomForest	California	-2.42	-2.44	-2.52	+3.71%	+3.02%
Ridge	California	-4.77	-4.77	-4.77	-0.00%	0.00%
<i>Superconductivity (MSE)</i>						
CatBoost	Supercond.	-89.68	-90.87	-91.42	+1.91%	+0.61%
ElasticNet	Supercond.	-312.77	-313.21	-313.70	+0.30%	+0.16%
Lasso	Supercond.	-311.94	-311.96	-311.96	+0.01%	0.00%
RandomForest	Supercond.	-90.30	-92.12	-93.62	+3.54%	+1.60%
Ridge	Supercond.	-311.49	-311.47	-311.47	-0.00%	0.00%

Таблица: Сравнение методов оптимизации на задачах регрессии.



Жирным отмечен положительный прирост над случайным поиском, курсивом — отрицательный.

Приведенные результаты получены после 50 итераций подбора параметров

Краткие выводы для регрессии

- **Значимый выигрыш** (до +3.71%) только для ансамблевых моделей (RandomForest, CatBoost).
 - *Причина:* сложный многомерный ландшафт гиперпараметров (глубина, число деревьев, регуляризация) требует интеллектуального исследования.
- **GP уверенно опережает TPE** (напр., RandomForest на California: +3.71% против +3.02%).
 - *Причина:* гауссовский процесс строит более точную глобальную суррогатную модель, лучше улавливая взаимодействия параметров. TPE с одномерными оценками плотности сходится медленнее при ограниченном бюджете итераций.
- **Линейные модели** (Ridge, Lasso, ElasticNet) практически не улучшаются.
 - *Причина:* их пространство гиперпараметров практически одномерно (α), ландшафт «плоский» вблизи оптимума. Даже случайный поиск быстро его находит.

Графики сходимости



Байесовские
методы

Фетисов
Григорий

Постановка
задачи

Используемые
данные и
модели

Используемые
методы

Результаты

Только дискретные параметры (RandomForestRegressor, California)

Метод	Лучший neg_MSE	Прирост над Random
GP (EI)	-2.530×10^9	+0.20%
TPE	-2.518×10^9	+0.68%
Random	-2.535×10^9	—

Таблица: Пространство: `n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf`, `max_features`.

Интерпретация

- **TRE** вышел на первое место с заметным отрывом (+0.68% над Random).
- GP показал скромное улучшение над случайным поиском (+0.20%).
- При чисто дискретном пространстве преимущество гауссовского процесса исчезает — TRE работает точнее.

Эволюция лидеров при сужении пространства

Тип пространства	Лучший метод
Полное (непрерывные + дискретные)	GP
Фиксированы непрерывные (оставлены дискретные)	TPE

Причины смены лидера

- **Гауссовский процесс** силен в непрерывных областях — он строит гладкую суррогатную модель и точно предсказывает улучшения.
- Когда остаются только дискретные параметры, гладкая модель GP становится неточной, и оптимизация сводится к исследованию небольшого числа комбинаций.
- **TRE**, напротив, изначально использует одномерные оценки плотности и лучше адаптирован к дискретным и условным переменным.

Репозиторий на GitHub

<https://github.com/Fetis789/OptimizationProjectBayes>

В репозитории: ноутбуки с полным пайплайном, логи всех экспериментов, графики динамики оптимизации и итоговые таблицы.