



ЦЕНТРАЛЬНЫЙ
УНИВЕРСИТЕТ

Влияние выбора контрастивной функции потерь на качество обучения предложенческих эмбеддингов

Спикер: Нечепоренко Дарья Евгеньевна
Команда: Не сошлось b_d

Содержание

→ Введение

→ Теоретическая часть

→ Описание постановки эксперимента

→ Интеграция решения в продакшн агентов

→ Выводы

Введение



Введение

Sentence embeddings — плотные векторные представления предложений, в которых семантически близкие предложения расположены рядом в пространстве. Они являются основой для задач semantic search, question answering, document clustering и NLI.


Предобученные трансформеры (BERT, MiniLM) дают текстовые представления, но они не оптимизированы для задачи семантического сходства напрямую. Fine-tuning с контрастивными функциями потерь позволяет адаптировать эмбединговое пространство под эту задачу.

Открытый вопрос

Какая функция потерь эффективнее — и зависит ли ответ от режима supervision?

Введение

Схема



Метрика оценки

Корреляция Спирмена между $\text{cosine_sim}(e1, e2)$ и человеческими оценками схожести на STS Benchmark (значения от 0 до 5, нормализованные в $[0, 1]$).

Три подхода к обучению эмбедингов



InfoNCE (NT-Xent)

$$\mathcal{L}_{InfoNCE} = -\log \frac{\exp(\text{sim}(a, p)/\tau)}{\sum_j \exp(\text{sim}(a, j)/\tau)}$$

- $\text{sim}(u, v) = \cos(u, v)$ — косинусное сходство нормализованных векторов
- $\tau = 0.05$ — температурный параметр (чем меньше, тем резче распределение)
- Все примеры батча кроме positive служат in-batch негативами
- Формально: cross-entropy по диагонали матрицы сходств



Triplet Loss

$$\mathcal{L}_{Triplet} = \max(0, d(a, p) - d(a, n) + \text{margin})$$

- $d(u, v) = 1 - \cos(u, v)$ — косинусное расстояние
- $\text{margin} = 0.3$ — минимальный желаемый зазор между позитивным и негативным расстоянием
- Тройки: (anchor, positive, negative) из корпуса NLI или STS



Cosine Similarity Loss

$$\mathcal{L}_{Cosine} = \text{MSE}(\cos(e_1, e_2), \text{target_score})$$

- $\text{target_score} \in [0, 1]$ — для NLI: entailment=1.0, neutral=0.5, contradiction=0.0; для STS: human_score / 5.0
- Единственный лосс с явным числовым supervision сигналом

Сравнение функций потерь

Чем отличаются подходы?

Свойство	InfoNCE	Triplet	Cosine MSE
Входные данные	(anchor, positive)	(anchor, positive, negative)	(s1, s2, score)
Тип supervision	Бинарный (похожи / нет)	Относительный порядок	Числовой скор
Негативы	In-batch автоматически	Явные негативы	Не нужны
Температура	$\tau = 0.05$	—	—
Margin	—	0.3	—
Качество негативов	Зависит от batch size	Определяется порогами	—
Требует STS для обучения?	Нет (NLI достаточно)	Нет (NLI достаточно)	Нет (NLI: авто-скоры)

Откуда берутся данные

SNLI + MNLI (NLI-only режим)

- ~550 000 пар предложений с метками: *entailment*, *neutral*, *contradiction*
- Для InfoNCE: пары (premise, hypothesis) с меткой entailment → (anchor, positive)
- Для Triplet: тройки (premise, entailment_hyp, contradiction_hyp)
- Для Cosine: пары + скор: entailment=1.0, neutral=0.5, contradiction=0.0

STS Benchmark train (STS-only режим)

- 5 749 пар предложений с человеческими оценками схожести [0, 5] → нормализованы в [0, 1]
- Для InfoNCE: пары с score ≥ 0.5 как (anchor, positive)
- Для Triplet: тройки, где positive: score ≥ 0.6 ; negative: score ≤ 0.3
- Для Cosine: все пары с нормализованным скором напрямую

Оценочный корпус: STS Benchmark

- STS dev (1 500 пар) — валидация во время обучения, выбор лучшего чекпоинта
- STS test (1 379 пар) — финальная оценка, **не используется ни разу во время обучения**

Evaluation protocol

Spearman ρ между $\text{cosine_sim}(e1, e2)$ и нормализованными человеческими оценками на STS test.

Модели и базовые показатели (Baseline)

Модель	Spearman (STS test)
MiniLM-L6	0.8203
BERT-base	0.4729

Модель	Параметры	Слоёв	Скрытое состояние	Особенность
all-MiniLM-L6-v2	~22M	6	384	Уже дистиллирована для sentence similarity
bert-base-uncased	~110M	12	768	Общее предобучение, не специализирована

Ключевое наблюдение: MiniLM-L6 изначально очень сильная (уже дообучена для похожей задачи). BERT-base — слабый baseline, что создаёт большой потенциал для улучшения.

Постановка эксперимента

Детали эксперимента

Итого: $2 \times 2 \times 3 \times 4 = 48$ запусков

Ось	Значения
Модели	MiniLM-L6, BERT-base
Режимы supervision	NLI-only, STS-only
Функции потерь	InfoNCE, Triplet, Cosine
Learning rate	1e-5, 2e-5, 3e-5, 5e-5

Заморозка слоёв: обучаются только последние 2 трансформерных блока + pooler. Всё остальное (embedding layer, слои 0–9 у BERT, 0–3 у MiniLM) заморожено.


- BERT-base: обучается ~12% параметров (~13M из ~110M)
- MiniLM-L6: обучается ~20% параметров (~4.5M из ~22M)

Мотивация заморозки: ускорение обучения, снижение риска catastrophic forgetting предобученных знаний, снижение переобучения на малых STS данных.

Прочие настройки:

- Оптимизатор: AdamW, weight_decay=1e-2
- Scheduler: linear warmup (100 шагов) + linear decay
- Число эпох: 10
- Batch size: 64
- Mixed precision (fp16): включено при наличии CUDA
- Gradient clipping: max_grad_norm=1.0
- Pooling: mean pooling по токенам с учётом attention mask
- Чекпоинт: сохраняется модель с **лучшим Spearman на STS dev** (не последняя эпоха)
- Seed: 42 для воспроизводимости

Результаты: тепловые карты




Вывод

При NLI-supervision лидирует **InfoNCE** — in-batch негативы из большого корпуса создают плотный обучающий сигнал

При STS-supervision лидирует **Cosine** — числовой скор идеально совпадает с метрикой оценки
Triplet занимает промежуточную позицию в обоих режимах

Результаты: NLI-only vs STS-only





Вывод

Для **Cosine loss**: STS значительно лучше — supervision сигнал напрямую соответствует метрике
Для **InfoNCE**: NLI немного лучше для обеих моделей — большой корпус (550K пар) vs маленький STS train (5.7K)

Для **Triplet**: STS немного лучше или паритет

Победитель по режиму: STS-only обгоняет NLI-only в большинстве случаев, несмотря на в ~100x меньший датасет

Результаты: Сравнение моделей



Вывод



BERT-base стартует с низкого baseline (не специализирован) → после fine-tuning почти догоняет MiniLM

MiniLM уже сильная — fine-tuning даёт небольшой, но стабильный прирост

Оба хорошо реагируют на STS-only + Cosine

Средний Spearman: MiniLM (0.807) > BERT (0.750) по всем 24 конфигурациям

Результаты: Сходимость train loss




Вывод

InfoNCE: при $lr=5e-5$ наблюдается более нестабильное начало обучения (большие осцилляции loss), при малых LR сходимость плавная

Triplet: лосс стабильно убывает при всех LR; при большом LR иногда небольшие всплески

Cosine: самый гладкий loss — MSE-регрессия предсказуемо убывает; NLI-only сходится медленнее, чем STS-only (из-за большего датасета)

Кривые STS-only значительно короче по числу шагов (датасет в $\sim 100\times$ меньше)



Результаты: Динамика Spearman(val) по эпохам






Вывод

InfoNCE (NLI): лучшая точка обычно на эпохах 5–9; кривые относительно стабильны после 3-й эпохи



Triplet: лучшая точка часто на эпохах 1–4; после некоторого момента небольшое ухудшение (признаки переобучения при больших LR)

Cosine (STS-only): лучшая точка на эпохах 4–8; очень быстрый выход на плато из-за малого датасета

Ключевое наблюдение: сохранение по лучшей валидации критично — использование финальной эпохи ухудшило бы результаты в нескольких конфигурациях





Результаты: Чувствительность к LR



Вывод

InfoNCE наиболее стабилен к LR — разброс результатов по 4 LR минимален
Cosine (NLI-only) наиболее чувствителен — кривая ярко выраженная, неправильный LR сильно снижает качество
STS-only режим в целом менее чувствителен к LR, чем NLI-only — малый датасет меньше позволяет переобучиться
Для практического применения рекомендуется $lr=3e-5$ как хороший компромисс

Результаты: Grad Norm и время обучения




Вывод

STS-only в 30–100× быстрее, чем NLI-only — при сопоставимом или лучшем качестве
NLI-only + Cosine — самый дорогой вариант, при этом не лучший по качеству
Scatter plot time vs quality показывает: левый верхний (быстро + качественно) занят STS-only + Cosine/InfoNCE



Рейтинг функций потерь



Вывод

InfoNCE — лучший по среднему и наиболее стабильный (меньший std)

Cosine — лучший максимум (0.853), но менее стабильный: сильно зависит от режима supervision

Triplet — стабильный средний результат, но нигде не лидирует

Победитель зависит от задачи: если есть размеченные пары с числовыми оценками → Cosine; если только метки NLI → InfoNCE

Выводы

Влияние лосса зависит от данных

- NLI-corpus → InfoNCE лучше (in-batch негативы из 550K пар)
- STS-annotations → Cosine лучше (supervision напрямую совпадает с метрикой)

01

STS-only: неожиданно эффективен

5 749 пар с человеческими оценками дают результат не хуже, чем 550 000 пар NLI — при в 100x меньших вычислительных затратах.

Частичное объяснение: STS train/dev/test — один бенчмарк, одна схема аннотации
консистентность распределений.

02

BERT-base улучшается кардинально

baseline 0.473 → fine-tuned 0.820 (+0.347) —
дообучение критически важно для моделей без специализации

03

InfoNCE наиболее стабилен к LR

практически важно для быстрого подбора гиперпараметров

04


QR-code



Репозиторий с исследованием

**Спасибо
за внимание!**

Спикер: Нечепоренко Дарья Евгеньевна





**ЦЕНТРАЛЬНЫЙ
УНИВЕРСИТЕТ**

Список источников литературы

Gao T., Yao X., Chen D. SimCSE: Simple Contrastive Learning of Sentence Embeddings // EMNLP 2021. arXiv: 2104.08821. — контрастивное обучение предложенческих эмбеддингов с in-batch негативами, ближайший аналог InfoNCE подхода из работы.

Reimers N., Gurevych I. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks // EMNLP 2019. arXiv: 1908.10084. — основополагающая работа по fine-tuning BERT для задачи семантического сходства с использованием siamese-архитектуры и triplet/cosine loss.

Wang T., Isola P. Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere // ICML 2020. arXiv: 2005.10242. — теоретическое обоснование того, почему контрастивные функции потерь работают: метрики alignment и uniformity.

van den Oord A., Li Y., Vinyals O. Representation Learning with Contrastive Predictive Coding // arXiv: 1807.03748, 2018. — оригинальная статья, где введён InfoNCE loss с температурным параметром.

Giorgi J. et al. DeCLUTR: Deep Contrastive Learning for Unsupervised Textual Representations // ACL 2021. arXiv: 2006.03659. — применение контрастивного обучения к текстовым представлениям без разметки, близко к NLI-режиму из работы.

Devlin J. et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // NAACL 2019. arXiv: 1810.04805. — базовая статья по BERT, архитектура которого используется как основа для дообучения.

Cer D. et al. STS Benchmark as a Shared Task for Semantic Textual Similarity // SemEval 2017. arXiv: 1708.00055. — описание бенчмарка STS, используемого в работе как основная метрика оценки качества.

Schroff F., Kalenichenko D., Philbin J. FaceNet: A Unified Embedding for Face Recognition and Clustering // CVPR 2015. arXiv: 1503.03832. — оригинальная статья, где введён triplet loss.

