

Оптимизация выбора длин волн для выявления ранних признаков патологий листьев томата на примере мучнистой росы



TomatoTeam, Андреевская А.С., Зубко Д.В.

Постановка задачи




О чем: отбор информативных спектральных диапазонов для диагностики заболевания /стадий заболевания

Зачем: находить заражения томатов мучнистой росой на предсимптомной стадии

Гипотеза: существуют определенные диапазоны волн, которые не уступают или почти также полезны, как весь спектр

Приложение: агротехнологии
Как измеряем качество:
сбалансированная точность по классам




$$R(\lambda) = \frac{I(\lambda)}{W(\lambda)}$$

$I(\lambda)$ — средний сигнал листа
 $W(\lambda)$ — сигнал белого эталона
 $R(\lambda)$ — нормированный коэффициент отражения



Модель сегментации:
SAM3 (Segment Anything Model 3)



Данные



Объект: томат *Solanum lycopersicum* L., линия 271/23.

Контроль
30 растений; без заражения
Заражение
50 растений; *Erysiphe necotycopersici*

Гиперспектральная съемка:
• SpecIm IQ — VNIR-диапазон, 400–1000 нм;
• SpecIm FX17 — NIR/SWIR-диапазон, 900–1700 нм.

Камера	Задача	Количество образцов, шт.	Train, шт.	Test, шт.	Классы
FX17	здоровые / больные	905	725	180	больные: 580; здоровые: 325
FX17	временные стадии после инокуляции	580	465	115	ранняя: 280; поздняя: 100; симптоматическая: 50; переходная: 150
IQ	здоровые / больные	770	615	155	больные: 500; здоровые: 270
IQ	временные стадии после инокуляции	500	400	100	ранняя: 200; поздняя: 100; симптоматическая: 100; переходная: 100

Этап	Дата
Посев	05.03.2026
Пикировка	13.03.2026
Первичная инокуляция	02.04.2026
Ежедневная съемка	с 02.04.2026
Повторная инокуляция	10.04.2026
Перерыв в съемках	11–12.04.2026
Завершение эксперимента	17.04.2026

Длительность эксперимента: 15 дней
Длительность съемки: 13 дней

Методы

Метод	Тип	Сложность	Особенность
Полный спектр	бейзлайн	$O(TnpC)$	Логистическая регрессия на всех p волнах; отбора нет, верхний ориентир качества.
Взаимная информация (MI) + LR	Фильтр по p + LR	$\approx O(pn \log n) + O(TnkC)$	Оценивает зависимость $I(X_j; y)$, может ловить нелинейность; признаки рассматриваются по отдельности.
SPA + LR	жадный + LR	$\approx O(knp) + O(TnkC)$	Жадно выбирает релевантные и менее коллинеарные волны; не гарантирует глобальный оптимум.
ADMM + LR	LR	$O(p^2n) + O(T_{ADMM}p^3) + O(TnkC)$	ADMM решает разреженного отбора с регуляризацией, затем выбираются топ-12 по $\ B_j\ _2$ и обучается одинаковая LR.
ADMM LS	выпуклая негладкая	$O(p^2n) + O(T_{ADMM}p^3)$	Прямой классификатор XB без жесткого топ-k.

Обозначения: n — число объектов, p — число длин волн, $k=12$ — число выбранных волн (на основе короткого теста метрик), T — итерации LR, C — число классов,

Методы

Бейзлайны отбора волн + LR

Данные: $X \in R^{(n \times p)}$, где Y — классы; S_k — выбранные k волн. Полный спектр обучается на всех p волнах.

Общий вид задачи:

1. рассчитывается оценка информативности $Score_j$ для каждой длины волны;
2. выбирается подмножество:
 $S_k = Top_k(Score_j), j = 1, \dots, p$
3. логистическая регрессия обучается на $X[:, S_k]$

Используемые критерии:

- взаимная информация: зависимость между спектральным признаком и классом;
- SPA: жадный отбор с учетом информативности и снижения коллинеарности.

Основная ADMM-модель

Классификатор на основе разреженной МНК-модели с согласованием соседних волн:

$$\min_B \frac{1}{2n} \|XB - Y\|_F^2 + \lambda_1 \|\beta\|_1 + \lambda_{TV} \|D\beta\|_1 + \frac{\lambda_2}{2} \|B\|_F^2$$

Где $B \in R^{(p \times c)}$ — коэффициенты волн по классам;
 D — матрица первых разностей по соседним волнам;
 $\|\beta\|_1$ — разреженность;
 $\|D\beta\|_1$ — спектральная согласованность.

ADMM разбиение:

$$Z = B, V = DB$$

переменные B, Z и V обновляются итерационно, для Z и V используется пороговая обработка.

Прямое предсказание ADMM:

$$\hat{y}_i = \arg \max_c (x_B^T) c$$

ADMM топ-12 + LR:

$$S_{ADMM} = top - 12(\|\beta\|_2^4), \text{ затем LR на } X[:, S_{ADMM}]$$

Результаты. IQ / бинарная



Задача	Метод	Accuracy	Balanced Accuracy	Признаки	Время, сек
здоровые / больные	Полный спектр LR	0.993	0.989	204	1.28
здоровые / больные	MI top-12 + LR	0.889	0.889	12	0.61
здоровые / больные	SPA top-12 + LR	0.933	0.950	12	0.22
здоровые / больные	ADMM direct LS	0.985	0.989	200	23.57
здоровые / больные	ADMM top-12 + LR	0.889	0.889	12	23.58



Результаты. IQ / стадии

Задача	Метод	Ассигасу	Balanced Ассигасу	Признаки	Время, сек
временные стадии	Полный спектр LR	0.998	0.998	204	0.04
временные стадии	MI top-12 + LR	0.998	0.998	12	0.56
временные стадии	SPA top-12 + LR	0.971	0.969	12	0.10
временные стадии	ADMM direct LS	0.957	0.981	204	25.03
временные стадии	ADMM top-12 + LR	0.986	0.994	12	25.04



Результаты. FX / бинарная

Задача	Метод	Accuracy	Balanced Accuracy	Признаки	Время, сек
здоровые / больные	Полный спектр LR	0.938	0.951	224	2.34
здоровые / больные	MI top-12 + LR	0.751	0.767	12	0.82
здоровые / больные	SPA top-12 + LR	0.774	0.775	12	0.17
здоровые / больные	ADMM direct LS	0.831	0.879	219	17.84
здоровые / больные	ADMM top-12 + LR	0.836	0.839	12	17.84




Результаты. FX / стадии

Задача	Метод	Ассигасу	Balanced Assigasy	Признаки	Время, сек
временные стадии	Полный спектр LR	0.824	0.789	224	0.10
временные стадии	MI top-12 + LR	0.613	0.507	12	0.83
временные стадии	SPA top-12 + LR	0.571	0.457	12	0.14
временные стадии	ADMM direct LS	0.689	0.616	221	15.97
временные стадии	ADMM top-12 + LR	0.697	0.708	12	15.98


Результаты




IQ / бинарная




IQ / стадии




FX / бинарная



FX / стадии



Результаты



Результаты

Эксперимент	ADMM топ-12 волн	Биологическая интерпретируемость
IQ / бинарная	663.8, 660.8, 657.9, 654.9, 495.9, 498.8, 501.7, 504.6, 507.6, 510.5, 513.4, 516.3	496–516 нм — видимая зелено-сине-зеленая область, связанная с изменениями пигментного состава листа; в видимом диапазоне 400–700 нм отражение листьев в основном определяется фотосинтетическими пигментами: хлорофиллами и каротиноидами. 655–664 нм — красная область поглощения хлорофилла: у хлорофилла максимум красного поглощения находится около 661–665 нм, поэтому этот диапазон можно связать с содержанием хлорофилла и фотосинтетическим стрессом.
IQ / стадии	400.2, 403.1, 417.5, 414.6, 411.7, 420.4, 423.3, 426.2, 408.9, 429.1, 654.9, 657.9	400–429 нм — синяя область видимого диапазона, где поглощают хлорофиллы и каротиноиды; для хлорофиллов описаны максимумы в синей области около 428 и 453 нм, а каротиноиды имеют широкое поглощение в области 400–500 нм. 655–658 нм — область красного поглощения хлорофилла, потенциально чувствительная к изменению пигментного аппарата по мере развития заболевания.
FX / бинарная	1500.0, 1496.4, 1492.9, 1489.3, 1485.7, 1482.1, 1478.6, 1475.0, 1471.4, 1467.9, 1464.3, 1403.6	1403.6 и 1464–1500 нм — SWIR/NIR-область, связанная прежде всего с водным статусом листа. Для растительных листьев характерны полосы поглощения воды около 1450 нм, а также связь О–Н колебаний воды с диапазонами около 975, 1175, 1450 и 1950 нм. Поэтому выбор ADMM в районе 1400–1500 нм можно интерпретировать как чувствительность к гидратации тканей и водному стрессу.
FX / стадии	921.4, 925.0, 1650.0, 1653.6, 928.6, 1646.4, 932.1, 1335.7, 1135.7, 1139.3, 1142.9, 1146.4	921–932 нм — ближняя ИК-область, чувствительная к внутренней структуре листа и водному статусу. 1136–1146 нм находится рядом с водной О–Н областью около 1175 нм, поэтому может отражать изменения водного состояния. 1335.7 нм и 1646–1654 нм относятся к SWIR-областям, где отражение листа определяется не только водой, но и биохимическими/структурными компонентами, включая белки, целлюлозу и лигнин.

Выводы

Основные результаты проекта:

Компактные наборы длин волн действительно могут сохранять значительную часть диагностической информации полного спектра, особенно для IQ/VIS-NIR. Для FX17 сокращение до 12 волн оказалось более сложным и сильнее зависело от метода отбора. ADMM дал интерпретируемую оптимизационную постановку и позволил учитывать согласованность соседних спектральных каналов, но требует дальнейшего подбора параметров и проверки устойчивости выбранных диапазонов.

Что планировалось:

выбрать небольшой набор информативных длин волн, который сохраняет качество классификации по сравнению с полным спектром.

Что получилось:

для IQ полный спектр и компактные топ-12 методы дают высокое качество; Для FX17 полный спектр сохраняет более высокое качество, а жесткий топ-12 отбор приводит к потере части информации. ADMM дал интерпретируемые спектральные диапазоны.

Как улучшить:

ускорить ADMM, адаптивно подбирать параметры и число волн, а также разбить выбранные диапазоны на спектральные кластеры и проверить качество классификации по отдельным кластерам и их комбинациям.

GitHub



<https://github.com/usernameMAI/OptimizationMethods>